

LangSmith Verantwoording

Eva Multi-Agent

Over dit document

Dit document verantwoordt de LangSmith-metingen voor de Eva Multi-Agent applicatie. Verwijzingen naar "stap" verwijzen naar STAPPEN.md in de GitHub-repository.

Repository: [STAPPEN.md](#) | LangSmith Project: eva-marketing-agent

Inhoudsopgave

1. Agent volgorde & tokenpatroon	2
Gemiddelde tokenverdeling per agent (1 iteratie, ~8.500 tok)	2
2. Versies & gemeten data	2
V1 – Baseline	3
V1b – Error runs (Groq rate limit)	3
V2 – Langere input	3
V3 – 3 feedback iteraties (lange input)	4
V4 – Skills map	4
V5 – Tools: DuckDuckGo + Wikipedia	5
V6 – RAG: PDF ingestion	5
V7 – RAG + boek-PDF: Een jaar in de Molukken	6
V8 – Dynamische skills per campaign_type	6
V9 – Human-in-the-loop + RAG-bronnen	7
3. Kosten – Groq free tier (100.000 tok/dag)	7
4. Provider strategie & dagelijkse capaciteit	8
Huidige configuratie (alles op Groq)	8
Best split (met OpenRouter)	8
Vergelijking dagelijkse capaciteit	9

1. Agent volgorde & tokenpatroon

LangSmith trackt automatisch elke LLM-aanroep in LangGraph: tokens per agent, latency en iteraties. Setup: Stap 16 | Werkend: Stap 17. Alle cijfers zijn gemeten via de LangSmith API.

Researcher → Strateeg → Copywriter → Social Specialist → Campaign Manager

Elke agent ontvangt de volledige state van alle voorgaande agents. Dit verklaart de stijgende tokenkosten: de Campaign Manager is de duurste agent, de Researcher de goedkoopste.

Gemiddelde tokenverdeling per agent (1 iteratie, ~8.500 tok)

Agent	Gem. tokens	Toelichting
Researcher	~1.835 tok	Eerste agent, geen vorige context
Strateeg	~3.093 tok	Ontvangt output Researcher
Copywriter	~3.179 tok	Ontvangt output Strateeg
Social Specialist	~3.269 tok	Ontvangt output Copywriter
Campaign Manager	~5.516 tok	Ontvangt volledige state – duurste agent



2. Versies & gemeten data

V1 – Baseline

V1 – Baseline Stap: 17	
Product	Eco-Cup Go
Input	Kort
Iteraties	1
Runs	8 runs
Tokens	8.036 – 8.775 tok gemiddeld 8.460 tok
Latency	10–12 seconden

	LangGraph	Eco-Cup Go: Een herbruikbare, opvouw...	**Headline:** Duurzame Koffie, Mind...	3/25/2026, 2:...	12.06s			8,609
	LangGraph	Eco-Cup Go: Een herbruikbare, opvouw...	De markt voor herbruikbare koffiebek...	3/25/2026, 2:...	10.47s			8,731
	LangGraph	Eco-Cup Go: Een herbruikbare, opvouw...	De Eco-Cup Go zal worden gepositio...	3/25/2026, 1:...	11.77s			8,483

V1b – Error runs (Groq rate limit)

V1b – Error runs Stap: 21	
Probleem	Groq 429 rate limit – pipeline halverwege gestopt
Runs	4 runs afgebroken
Tokens	2.201 / 2.804 / 2.672 / 6.504 tok

RateLimitError("E...	3/25/2026, 3:...	12.04s			6,504
NotFoundError("E...	3/25/2026, 3:...	3.13s			2,672
RateLimitError("E...	3/25/2026, 3:...	5.91s			2,804
RateLimitError("E...	3/25/2026, 3:...	6.05s			2,201


V2 – Langere input

V2 – Langere input Stap: 22	
Iteraties	1
Runs	2 runs
Tokens	15.448 tok (98.8s) en 18.334 tok (71.8s)
Vergelijking	Circa 2× meer tokens dan V1 door langere product_description

gestreepte t-shirts:rood, roze	--**Segment-gericht***: Richt de cam...	3/25/2026, 6:...	98.81s			15,448
Burning Barrel	campaigns/images/campaign_20260...	3/25/2026, 3:...	71.76s			18,334

V3 – 3 feedback iteraties (lange input)

V3 – 3 feedback iteraties		Stap: 10 + 11
Iteraties	3	
Runs	1 run	
Totaal tokens	47.374 tok (131.3s)	
Vaste kosten	Researcher + Strateeg (1×): 5.473 tok	
Variabele kosten	Copywriter + Social + CM (3×): 41.901 tok	



V4 – Skills map

V4 – Skills map		Stap: 24
Iteraties	1	

Tokens	21.695 tok goedgekeurd door Campaign Manager
System prompts	Researcher ~417 Strateeg ~260 Copywriter ~328 Social ~336 CM ~336 tok
Toelichting	Extra tokens door skills in system prompts

V5 – Tools: DuckDuckGo + Wikipedia

V5 – Tools: DuckDuckGo + Wikipedia Stap: 26	
Iteraties	1
Tokens	27.596 tok goedgekeurd door Campaign Manager
Per agent	Researcher: 3.123 Strateeg: 6.758 Copywriter: 5.264 Social: 5.255 CM: 7.196 tok
vs. V4	+5.901 tok (+27%) – Researcher output rijker door search snippets

Tokenverdeling: V4 vs V5

V4 – Zonder tools	V5 – Met DuckDuckGo + Wikipedia
	

V6 – RAG: PDF ingestion

V6 – RAG: PDF ingestion Stap: 25 + 26	
PDF	philips-airfryer_double.pdf
Run ID	019d3aaf-0816-7651-add2-8cfad538e29f
Iteraties	3 (max bereikt)
Totaal tokens	55.496 tok (prompt: 34.390 completion: 21.106)
RAG	5× VectorStoreRetriever (geen LLM tokens)
vs. V5	+27.900 tok (+101%) – rijkere Researcher input leidt tot meer revisierondes

Tokenverdeling V6 per agent

Agent	Prompt tokens	Completion tokens
Researcher	2.716 (+1.834 door PDF)	2.300
Strateeg	2.412	1.775
Copywriter (3 iter.)	2.767 / 3.831 / 3.759	674 / 1.422 / 1.182
Social Specialist (3 iter.)	2.552 / 2.505 / 2.588	1.333 / 2.394 / 1.501
Campaign Manager (3 iter.)	3.722 / 3.691 / 3.847	3.035 / 2.871 / 2.619

Provider verdeling V6 (alles OpenRouter)

Alle agents draaien op nvidia/nemotron-3-nano-30b-a3b:free via OpenRouter. Token counts zijn schattingen op basis van de OpenAI tokenizer – werkelijke OpenRouter verbruikcijfers kunnen licht afwijken.

V7 – RAG + boek-PDF: Een jaar in de Molukken

V7 – RAG + boek-PDF Stap: 30–34	
Branch	feature/rag-pdf-ingestion
Datum	2026-03-29
PDF	Een-jaar-in-de-Molukken.pdf
Runs	4 runs iteraties: 1, 3, 3, 1 allemaal goedgekeurd
Bevinding	Boek-PDF leverde lege retrieval: USPs en marktcijfers staan niet in een boek

Gevonden hallucinaties

- Verzonnen auteurbiografie (historicus, zoon van Molukse immigranten)
- Gefabriceerde persoon: Dr. Marielle Sari, cultuurhistoricus bij het Rijksmuseum van Ethnologie
- Digitale producten die niet in het boek staan: interactieve kaarten, audio-fragmenten

Oorzaak & fixes

Oorzaak: verkeerde queries aan de PDF leveren lege retrieval op, waarna het model de gaten zelf invult.

- No-fabrication regels in book-context.md en book-copywriting.md
- Aparte boek-queries: auteur, thema, historische context, uniekheid, leeservaring
- chunk_size 500 → 800 chars, top_k 3 → 2 (minder ruis in researcher-prompt)

Na die fixes: laatste run 1 iteratie, goedgekeurd, geen hallucinaties meer.

V8 – Dynamische skills per campaign_type

V8 – Dynamische skills Stap: 31

Branch	feature/rag-pdf-ingestion
Datum	2026-03-30 t/m 2026-03-31
Runs	7 runs (molukken, handboek kaasmaker ×2, boek over kaas ×2, boek over vegan kaas)
Iteraties	1–2 allemaal goedgekeurd
Nieuw	SKILL_MAP: elke agent laadt automatisch de juiste skills op basis van campaign_type
Token-schatting	Vergelijkbaar met V4 (~21.000 tok) – geen LangSmith data beschikbaar

V9 – Human-in-the-loop + RAG-bronnen**V9 – Human-in-the-loop** Stap: 47–48

Branch	feature/rag-pdf-ingestion
Datum	2026-04-07
Runs	6 runs (kaas, handboek kaasmaker, chocola ×3, molukkers in belgie)
Iteraties	1–3 allemaal goedgekeurd
Token effect	+500–800 tok per run met PDF (mismatch_check node)

Aanleiding & oplossing

Aanleiding: een chocolate-omschrijving met een kaas-PDF leverde gewoon een chocola-campagne op.

- Vaste onderwerpquery toegevoegd die altijd als eerste draait: "Waar gaat dit document over?"
- mismatch_check node: als productomschrijving ≠ PDF, pauzeert de graph via interrupt() en vraagt de gebruiker correctie. Daarna hervat de graph met Command(resume=...)

Nieuwe graph flow na V9

START → pdf_ingestion → mismatch_check → researcher → strateeg → copywriter → social → cm → image

Verder: researcher schrijft nu [Bron: N] na claims uit de PDF; de frontend toont een informatieicoon met de exacte passage en het paginanummer. Er is ook een Sources-tab bijgekomen.

3. Kosten – Groq free tier (100.000 tok/dag)

De onderstaande tabel toont het maximale aantal runs per dag op basis van de Groq free tier limieten.

Versie	Tokens	Max runs/dag (100k)
V1 – Baseline	~8.500	~11
V2 – Langere input	~17.000	~5
V3 – 3 feedback iteraties	~47.000	~2
V5 – Tools	~27.600	~3
V6 – RAG	~55.500	~1

4. Provider strategie & dagelijkse capaciteit

Agents draaien niet meer allemaal op dezelfde provider. AGENT_LLM_CONFIG in src/llm.py regelt per agent welk model en welke provider gebruikt worden.

Huidige configuratie (alles op Groq)

Agent	Model	Provider
Researcher	llama-3.1-8b-instant	Groq
Strateeg	llama-3.1-8b-instant	Groq
Copywriter	llama-3.3-70b-versatile	Groq
Social Specialist	llama-3.3-70b-versatile	Groq
Campaign Manager	llama-3.3-70b-versatile	Groq
RAG Embeddings	all-MiniLM-L6-v2	Lokaal (geen API tokens)

8B-agents (Researcher + Strateeg) ~9.900 tok per run limiet: 500k tok/dag	70B-agents (Copywriter + Social + CM) ~17.700 tok per run limiet: 100k tok/dag
---	--

Bottleneck: de 70B-limiet van 100.000 tok/dag → $100.000 \div 17.700 = \sim 5\text{--}6$ runs per dag.

Best split (met OpenRouter)

Agents	Provider & model	Capaciteit
Researcher + Strateeg	Groq – llama-3.1-8b-instant	500k tok/dag
Copywriter + Social Specialist	OpenRouter – llama-3.3-70b-instruct:free	50 req/dag globaal
Campaign Manager	Groq – llama-3.3-70b-versatile	100k tok/dag

Met de best split is de CM de enige 70B-agent op Groq: $100.000 \div 7.200 = \sim 13$ runs/dag.

Vergelijking dagelijkse capaciteit

Configuratie	Max runs/dag
V1 baseline – alles 8B op Groq	~11
Huidige split – 8B + 70B op Groq	~5–6
Best split – Groq + OpenRouter	~13